TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN

----□☯□----



BÁO CÁO MÔN HỌC

Tên đề tài : PRODUCT CLASSIFICATION AND CLUSTERING

(PHÂN LOẠI ĐA LỚP VÀ PHÂN CỤM SẢN PHẨM THƯƠNG MẠI ĐIỆN TỬ DỰA TRÊN HỌC MÁY)

Học phần : Máy học

Sinh viên tham gia :

Tên sinh viên	Mã số sinh viên
Huỳnh Quốc Danh	3124411050
Huỳnh Tấn Lộc	3124411158
Nguyễn Vĩnh Thịnh	3124411292
Mai Tấn Thiện Nhân	3124411196

Mục Lục

1. THÔNG TIN NHÓM THỰC HIỆN 3
2. GIỚI THIỆU BÀI TOÁN 4
3. XÁC ĐỊNH BÀI TOÁN MÁY HỌC 5
3.1. Nhánh 1: Bài toán Phân loại đa lớp có giám sát (Supervised Multi-class Classification) 5
3.2. Nhánh 2: Bài toán Phân cụm sản phẩm không giám sát (Unsupervised Clustering) 5
4. MÔ TẢ DỮ LIỆU 5
5. PHƯƠNG PHÁP DỰ KIẾN 7
6. KẾ HOẠCH THỰC NGHIỆM 8
7. KẾT QUẢ DỰ KIẾN 8
8. KẾ HOẠCH THỰC HIỆN (LỘ TRÌNH 06 TUẦN) 9
9. TÀI LIỆU THAM KHẢO 10

1. THÔNG TIN NHÓM THỰC HIỆN

- **Tên đề tài tiếng Anh:** Product Classification and Clustering.
- **Tên đề tài tiếng Việt:** Phân loại danh mục và phân cụm thực thể sản phẩm thương mại điện tử dựa trên các thuật toán Học máy có giám sát và không giám sát.

STT	Họ và tên sinh viên	MSSV	Vai trò	Phân công nhiệm vụ dự kiến
1	Huỳnh Quốc Danh	3124411050	Nhóm trưởng	Định hướng kiến trúc bài toán kép (Classification & Clustering), thiết kế pipeline TF-IDF/SVD, huấn luyện LinearSVC & LightGBM, tổng hợp báo cáo.
2	Mai Tấn Thiện Nhân	3124411211	Thành viên	Thu thập dữ liệu PriceRunner (UCI), phân tích khám phá dữ liệu (EDA), thống kê N-grams, phân tích phân phối 10 ngành hàng và 306 nhà bán hàng.
3	Huỳnh Tấn Lộc	3124411152	Thành viên	Tiền xử lý văn bản tiêu đề sản phẩm, trích xuất đặc trưng hình thái học (Morphological & Alphanumeric Features), chạy Baseline (Naive Bayes, Logistic).

4	Nguyễn Vĩnh Thịnh	3124411326	Thành viên	Triển khai nhánh Phân cụm (K-Means, Agglomerative Clustering, DBSCAN), trực quan hóa t-SNE/UMAP, xây dựng Web Demo (Streamlit) và slide.

2. GIỚI THIỆU BÀI TOÁN

- **Bối cảnh thực tiễn:** Trong kỷ nguyên thương mại điện tử (E-commerce) và các nền tảng so sánh giá trực tuyến (như PriceRunner, Google Shopping, Shopee, Lazada), hàng triệu sản phẩm mới từ hàng trăm nhà bán lẻ (Merchants) được cập nhật mỗi ngày. Mỗi nhà bán lẻ thường đặt tiêu đề sản phẩm (Product Title) theo cấu trúc, thứ tự từ khóa và quy ước viết tắt rất khác nhau cho cùng một mặt hàng thực tế (ví dụ: "Apple iPhone 8 Plus 64GB Silver" so với "Sim Free iPhone 8+ 64GB - Silver - Apple Smartphone").
- **Lý do lựa chọn & Ý nghĩa thực tiễn:** Việc tổ chức danh mục sản phẩm thủ công cho hàng chục nghìn mặt hàng tốn kém nhiều nhân lực và dễ sai sót. Đề tài Product Classification and Clustering giải quyết đồng thời 02 bài toán cốt lõi: (1) Tự động phân loại ngành hàng (Automatic Product Categorization): Gán chính xác sản phẩm mới đăng tải vào đúng danh mục chuẩn (Mobile Phones, TVs, CPUs, Washing Machines,...), giúp tối ưu bộ lọc tìm kiếm; và (2) Tự động gom cụm sản phẩm tương đồng (Unsupervised Product Clustering & Entity Matching): Nhóm các chào bán (Offers) của cùng một dòng sản phẩm từ nhiều cửa hàng khác nhau vào chung một cụm thực thể mà không cần gán nhãn trước, phục vụ so sánh giá tự động và chống trùng lặp danh mục.
- **Mục tiêu nghiên cứu:** (1) Khám phá đặc trưng ngôn ngữ của văn bản ngắn (Short-text Product Titles) và sự phân bố sản phẩm giữa 306 nhà bán lẻ trên bộ dữ liệu chuẩn PriceRunner của UCI; (2) Xây dựng và so sánh hiệu năng của 04 thuật toán Phân loại đa lớp có giám sát kết hợp biểu diễn TF-IDF Word/Char N-grams và đặc trưng hình thái học; (3) Triển khai và đối sánh 03 thuật toán Phân cụm không giám sát trên không gian giảm chiều TruncatedSVD (LSA); (4) Xây dựng ứng dụng Web Demo cho phép phân loại tức thời và gợi ý cụm sản phẩm tương đồng.
- **Câu hỏi nghiên cứu (Research Questions):** (RQ1) Việc kết hợp TF-IDF ở cả cấp độ từ (Word N-grams) và ký tự (Char N-grams) cùng đặc trưng mã hiệu chữ-số (Alphanumeric Model Tokens) giúp cải thiện độ chính xác phân loại các ngành hàng dễ nhầm lẫn (như Fridges, Freezers và Fridge Freezers) như thế nào? (RQ2) Giữa các thuật toán phân loại tuyến tính chiều cao (Multinomial Naive Bayes, Logistic Regression, LinearSVC) và học kết hợp (LightGBM), mô hình nào tối ưu nhất về Macro F1-Score và tốc độ suy luận? (RQ3) Trong bài toán không giám sát, các thuật toán phân cụm (K-Means, Agglomerative Clustering, DBSCAN) đạt mức độ tương đồng bao nhiêu (Silhouette Score, ARI, NMI) khi đối chiếu với nhãn danh mục và nhãn cụm thực tế?

3. XÁC ĐỊNH BÀI TOÁN MÁY HỌC

3.1. Nhánh 1: Bài toán Phân loại đa lớp có giám sát (Supervised Multi-class Classification)

- **Phát biểu toán học:** Cho tập dữ liệu huấn luyện D_sup = {(x_i, y_i)} (i = 1..N) với N = 35.311 bản ghi sản phẩm.
- **Dữ liệu đầu vào (Input x_i ∈ R^d):** Vector đặc trưng biểu diễn tiêu đề sản phẩm Product Title (sau khi trích xuất TF-IDF Word/Char N-grams và đặc trưng thống kê hình thái học) kết hợp thông tin mã nhà bán hàng Merchant ID.
- **Kết quả đầu ra (Output y_i ∈ {1, 2, ..., 10}):** Nhãn danh mục ngành hàng chuẩn (Category Label / Category ID gồm 10 lớp).
- **Mục tiêu học máy:** Tìm hàm phân lớp f: R^d → {1, ..., 10} cực tiểu hóa hàm mất mát Đa lớp (Multi-class Cross-Entropy hoặc Multi-class Hinge Loss) và tối đa hóa chỉ số Macro F1-Score trên tập kiểm thử độc lập.

3.2. Nhánh 2: Bài toán Phân cụm sản phẩm không giám sát (Unsupervised Clustering)

- **Phát biểu toán học:** Cho tập văn bản tiêu đề sản phẩm không sử dụng nhãn D_unsup = {z_i} (i = 1..N), trong đó z_i ∈ R^m (m << d) là vector biểu diễn sản phẩm sau khi giảm chiều bằng TruncatedSVD (Latent Semantic Analysis - LSA) và chuẩn hóa L2.
- **Dữ liệu đầu vào & Đầu ra:** Đầu vào là vector ngữ nghĩa ẩn z_i ∈ R^m; Đầu ra là nhãn cụm c_i ∈ {1, 2, ..., K} được gán tự động ở 02 cấp độ: (1) Phân cụm vĩ mô theo K = 10 nhóm ngành hàng; và (2) Phân cụm vi mô (Fine-grained Entity Clustering) gom các sản phẩm cùng mẫu mã thực tế.

4. MÔ TẢ DỮ LIỆU

- **Nguồn dữ liệu chính thống:** Bộ dữ liệu Product Classification and Clustering (pricerunner_aggregate.csv), công bố bởi Leonidas Akritidis et al. trên UCI Machine Learning Repository (ID: 837, DOI: 10.24432/C5M91Z) và Kaggle.
- **Đường dẫn truy cập:** https://archive.ics.uci.edu/dataset/837/product+classification+and+clustering
- **Quy mô dữ liệu:** Gồm 35.311 mẫu (instances) chào bán sản phẩm từ 306 nhà bán hàng (Merchants), thuộc 10 danh mục ngành hàng (Categories) và 13.237 cụm thực thể sản phẩm (Clusters), gồm 07 cột thuộc tính, không có giá trị khuyết (No Missing Values).

STT	Tên thuộc tính	Kiểu dữ liệu	Vai trò trong ML	Mô tả ý nghĩa và đặc điểm dữ liệu
1	Product ID	Integer	Định danh (Loại bỏ)	Mã số định danh duy nhất của từng bản ghi chào bán sản phẩm (1 – 47.358).

2	Product Title	Text / String	Đặc trưng chính (Input)	Tên/tiêu đề sản phẩm do nhà bán đăng tải (VD: "apple iphone 8 plus 64gb silver").
3	Merchant ID	Integer	Đặc trưng phụ (Input)	Mã định danh của nhà bán hàng (306 nhà bán hàng khác nhau).
4	Cluster ID	Integer	Nhãn đối chiếu Phân cụm	Mã định danh cụm thực thể sản phẩm chuẩn (Ground-truth Entity Cluster ID).
5	Cluster Label	Text / Categorical	Nhãn đối chiếu Phân cụm	Tên chuẩn hóa đại diện cho cụm sản phẩm (VD: "Apple iPhone 8 Plus (64GB)").
6	Category ID	Integer	Biến mục tiêu (Target)	Mã số định danh chuẩn của 10 danh mục ngành hàng.
7	Category Label	Categorical (10 lớp)	Biến mục tiêu (Target)	Tên danh mục ngành hàng: Fridge Freezers (5.501), Mobile Phones (4.081), Washing Machines (4.044), CPUs (3.862), Fridges (3.584), TVs (3.564), Dishwashers (3.424), Digital Cameras (2.697), Microwaves (2.342), Freezers (2.212).

- **Đặc điểm thách thức của dữ liệu:** (1) Văn bản ngắn chứa nhiều mã kỹ thuật (Short & Noisy Technical Text): độ dài 7–12 từ, nhiều mã model chữ-số (i7-8700k, ue55nu7100); (2) Chồng lấn từ vựng cao giữa 3 lớp Fridges (10,15%), Freezers (6,26%) và Fridge Freezers (15,58%); (3) Mất cân bằng nhẹ giữa các lớp.

5. PHƯƠNG PHÁP DỰ KIẾN

- **Bước 1 – Khám phá dữ liệu (EDA):** Thống kê phân phối độ dài tiêu đề (số ký tự, số từ, số token chữ-số) theo từng ngành hàng; phân tích tần suất Unigrams/Bi-grams bằng WordCloud & kiểm định Chi-square; phân tích ma trận chuyên doanh của 306 nhà bán hàng (Merchant ID × Category Label).
- **Bước 2 – Tiền xử lý dữ liệu (Data Preprocessing):** Chuẩn hóa khoảng trắng tên cột trong CSV gốc; chuyển chữ thường (Lowercasing); chuẩn hóa đơn vị đo lường (inch, gb, ghz, kg, rpm); lọc từ dừng tiếng Anh có chọn lọc nhưng bảo toàn toàn bộ con số và mã hiệu chữ-số.
- **Bước 3 – Xây dựng đặc trưng & Giảm chiều (Feature Engineering & LSA):** (1) Hybrid TF-IDF kết hợp Word N-grams (1,2) và Character N-grams (3,5); (2) Trích xuất 06 đặc trưng hình thái học (độ dài ký tự, số từ, số token số, số token chữ-số alphanumeric, độ dài từ trung bình, xác suất tiên nghiệm theo Merchant ID); (3) Giảm chiều bằng TruncatedSVD (LSA, m = 100–150 chiều) kèm chuẩn hóa L2 cho nhánh Phân cụm.
- **Bước 4 – Lựa chọn các mô hình Machine Learning so sánh (04 mô hình Phân loại & 03 mô hình Phân cụm):**

Nhánh bài toán	**Mô hình đề xuất**	**Cơ sở lý thuyết và lý do lựa chọn**
Phân loại đa lớp (Classification)	1. Multinomial Naive Bayes (Baseline)	Mô hình xác suất Bayes tốc độ cao trên ma trận tần suất TF-IDF, làm mốc tham chiếu cơ sở (Baseline).
Phân loại đa lớp (Classification)	2. Logistic Regression (Multinomial + L2)	Tối ưu hàm Cross-Entropy đa lớp, cung cấp xác suất hậu nghiệm rõ ràng và giải thích được trọng số từ khóa của từng ngành hàng.
Phân loại đa lớp (Classification)	3. Linear Support Vector Machine (LinearSVC)	Tìm siêu phẳng có lề cực đại (Maximum Margin) trong không gian TF-IDF số chiều lớn, kháng quá khớp vượt trội trên dữ liệu văn bản ngắn.
Phân loại đa lớp (Classification)	4. LightGBM / Random Forest (Ensemble)	Huấn luyện trên đặc trưng kết hợp (TruncatedSVD + Đặc trưng hình thái học + Merchant ID) để bắt tương tác phi tuyến.

Phân cụm (Clustering)	1. K-Means / Mini-Batch K-Means (Baseline)	Phân cụm tâm cụm trên vector LSA chuẩn hóa L2 (Spherical K-Means với độ đo Cosine) để phân tách K = 10 ngành hàng.
Phân cụm (Clustering)	2. Agglomerative Hierarchical Clustering	Phân cụm phân cấp từ dưới lên (Ward / Cosine Linkage), xây dựng cây Dendrogram minh họa cấu trúc phân cấp ngành hàng.
Phân cụm (Clustering)	3. DBSCAN / HDBSCAN (Density-based)	Phân cụm dựa trên mật độ không cần biết trước K, tự động gom các chào bán cùng mẫu sản phẩm (Entity Matching) và lọc nhiễu.

6. KẾ HOẠCH THỰC NGHIỆM

- **Phương pháp chia dữ liệu & Chống rò rỉ (Data Leakage Prevention):** Chia bộ dữ liệu theo tỷ lệ 80% Train (28.248 mẫu) và 20% Test (7.063 mẫu) bằng Stratified Split theo Category Label; đồng thời thử nghiệm kịch bản Group-aware Split theo Cluster ID. Áp dụng 5-Fold Stratified Cross-Validation trên tập Train. Toàn bộ TfidfVectorizer, TruncatedSVD, StandardScaler được đóng gói trong Pipeline chỉ fit trên tập Train.
- **Mô hình Baseline:** Multinomial Naive Bayes (nhánh Phân loại) và K-Means K = 10 trên không gian SVD 50 chiều (nhánh Phân cụm).
- **Các độ đo đánh giá (Evaluation Metrics):** (1) Nhánh Phân loại: Accuracy, Macro Precision, Macro Recall, Macro F1-Score, Weighted F1-Score và Confusion Matrix 10×10; (2) Nhánh Phân cụm: Độ đo nội tại (Silhouette Score, Davies-Bouldin Index) và Độ đo ngoại tại đối chiếu nhãn thực tế (Adjusted Rand Index - ARI, Normalized Mutual Information - NMI, V-Measure).
- **Phương án tinh chỉnh siêu tham số (Hyperparameter Tuning):** Sử dụng GridSearchCV & RandomizedSearchCV tối ưu theo f1_macro cho: TF-IDF (max_features, ngram_range, sublinear_tf); Naive Bayes (alpha); Logistic Regression & LinearSVC (C, class_weight); LightGBM (n_estimators, learning_rate, num_leaves); K-Means/Hierarchical/DBSCAN (số chiều SVD m, số cụm K qua Elbow/Silhouette, eps và min_samples).

7. KẾT QUẢ DỰ KIẾN

- **Sản phẩm bàn giao:** (1) Bộ mã nguồn Jupyter Notebooks chuẩn hóa (01_EDA, 02_Classification, 03_Clustering); (2) Báo cáo cuối kỳ và Slide thuyết trình kèm biểu đồ trực quan hóa không gian cụm 2D bằng t-SNE / UMAP; (3) Ứng dụng Web Demo tương tác bằng Streamlit cho phép nhập tên sản phẩm để phân loại danh mục tức thời và truy xuất cụm sản phẩm tương đồng từ các nhà bán hàng khác.

- **Kết quả mong đợi:** Mô hình Phân loại tốt nhất (LinearSVC / Hybrid TF-IDF + LightGBM) đạt Accuracy ≥ 95,0% và Macro F1-Score ≥ 0,94 trên tập Test; nhánh Phân cụm làm rõ hiệu quả của không gian ngữ nghĩa LSA qua các chỉ số Silhouette, ARI và NMI.

8. KẾ HOẠCH THỰC HIỆN (LỘ TRÌNH 06 TUẦN)

Thời gian	**Nội dung công việc chính**	**Thành viên phụ trách**	**Sản phẩm đầu ra (Deliverables)**
Tuần 1	Khảo sát bài toán, kiểm tra bộ dữ liệu UCI PriceRunner và hoàn thiện Proposal.	Cả nhóm (Danh chủ trì)	File Proposal PDF nộp Google Classroom.
Tuần 2	Thực hiện EDA: Thống kê 10 ngành hàng, 306 merchants, độ dài tiêu đề, WordCloud & N-grams.	Huỳnh Tấn Lộc, Nguyễn Vĩnh Thịnh	Notebook 01_EDA.ipynb & bộ biểu đồ phân tích.
Tuần 3	Xây dựng Pipeline tiền xử lý, trích xuất Hybrid TF-IDF, đặc trưng hình thái học & SVD.	Mai Tấn Thiện Nhân, Huỳnh Quốc Danh	Module feature_pipeline.py chống Data Leakage.
Tuần 4	Huấn luyện và tinh chỉnh 04 mô hình Phân loại (NB, Logistic, LinearSVC, LightGBM).	Mai Tấn Thiện Nhân, Nguyễn Vĩnh Thịnh	Bảng so sánh Metrics Phân loại & Confusion Matrix.
Tuần 5	Triển khai 03 mô hình Phân cụm (K-Means, Hierarchical, DBSCAN), vẽ t-SNE & làm Web Demo.	Huỳnh Tấn Lộc, Huỳnh Quốc Danh	Notebook Phân cụm, biểu đồ t-SNE & App Streamlit.
Tuần 6	Tổng hợp kết quả thực nghiệm, phân tích lỗi (Error Analysis), viết báo cáo và làm slide.	Cả nhóm	Báo cáo cuối kỳ, Slide thuyết trình & Source code.

9. TÀI LIỆU THAM KHẢO

[1] Akritidis, L. (2020), Product Classification and Clustering [Dataset], UCI Machine Learning Repository. DOI:https://doi.org/10.24432/C5M91Z.Truycậptại: https://archive.ics.uci.edu/dataset/837/product+classification+and+clustering.

[2] Akritidis, L., Fevgas, A., Bozanis, P., & Makris, C. (2020), "A Self-Verifying Clustering Approach to Unsupervised Matching of Product Titles", Artificial Intelligence Review (Springer), Vol. 53, pp. 4777–4820.

[3] Akritidis, L., Fevgas, A., & Bozanis, P. (2018), "Effective Product Categorization with Importance Scores and Morphological Analysis of the Titles", Proceedings of the 30th IEEE International Conference on Tools with Artificial Intelligence (ICTAI), pp. 213–220.

[4] Akritidis, L., & Bozanis, P. (2018), "Effective Unsupervised Matching of Product Titles with k-Combinations and Permutations", Proceedings of the 14th IEEE International Conference on Innovations in Intelligent Systems and Applications (INISTA), pp. 1–10.

[5] Pedregosa, F., et al. (2011), "Scikit-learn: Machine Learning in Python", Journal of Machine Learning Research (JMLR), Vol. 12, pp. 2825–2830.

[6] Géron, A. (2022), Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd Edition), O'Reilly Media.